


Прогнозирование рейтинга IMDb

Выполнила: студентка 332 группы Ульянова А.С.


Проверил: преподаватель кафедры теории вероятности Киселюс В.

Цель данного проекта — на основе данных о фильмах из базы IMDb (Internet Movie Database) спрогнозировать рейтинг фильма ещё до его выхода или до сбора большого количества оценок зрителей.


ay	Rank	Title	Genre	Description	Director	Actors	Year	Runtime (Minutes)
0	1	Guardians of the Galaxy	Action,Adventure,Sci-Fi	A group of intergalactic criminals are forced ...	James Gunn	Chris Pratt, Vin Diesel, Bradley Cooper, Zoe S...	2014	121
1	2	Prometheus	Adventure,Mystery,Sci-Fi	Following clues to the origin of mankind, a te...	Ridley Scott	Noomi Rapace, Logan Marshall-Green, Michael Fa...	2012	124
2	3	Split	Horror,Thriller	Three girls are kidnapped by a man with a diag...	M. Night Shyamalan	James McAvoy, Anya Taylor-Joy, Haley Lu Richar...	2016	117
3	4	Sing	Animation,Comedy,Family	In a city of humanoid animals, a hustling thea...	Christophe Lourdelet	Matthew McConaughey,Reese Witherspoon, Seth Ma...	2016	108
4	5	Suicide Squad	Action,Adventure,Fantasy	A secret government agency recruits some of th...	David Ayer	Will Smith, Jared Leto, Margot Robbie, Viola D...	2016	123



Распределение рейтинга




Распределение Log(Votes)



File display

Correlation matrix



Конструирование признаков

Жанры

Жанр представлен в виде строки с разделителями (например, Action, Adventure, Sci-Fi).

Это позволяет модели учитывать сочетания жанров, а не только основной.

Режиссёр

Для каждого режиссёра рассчитаны:

Средний рейтинг его предыдущих фильмов (Director_avg_rating)

Частота — сколько фильмов он снял (Director_freq)

Эти признаки отражают репутацию и опыт режиссёра.

Актёры

Аналогично режиссёрам:

Для каждого актёра вычислен средний рейтинг фильмов с его участием.

Для фильма — среднее по всем актёрам в составе.

Для неизвестных актёров используется глобальный средний рейтинг.

Моделирование

Использованные модели

Линейная регрессия (Linear Regression)

К-ближайших соседей (kNN, k=7)

Случайный лес (Random Forest, 300 деревьев)

Linear Regression

RMSE: 0.3517087599257042

R2: 0.8709537894094952

kNN


RMSE: 0.5973999788197832

R2: 0.627686065099589


Random Forest


RMSE: 0.2960760284721012

R2: 0.9085496486037318



3D кластеризация





Итоги прогнозирования

1. The Odyssey (Кристофер Нолан)

- Жанр: Adventure, Drama, Epic
- Актёры: Matt Damon, Tom Holland, Anne Hathaway
- Прогноз: 7.76

2. Killers of the Flower Moon 2 (Мартин Скорсезе)

- Жанр: Crime, Drama, History
- Актёры: Leonardo DiCaprio, Robert De Niro
- Прогноз: 7.70

- 3.Dune: Messiah (Дени Вильнёв) — 7.19
- 4.Jurassic World: Rebirth (Гарет Эдвардс) — 7.04
- 5.Avengers: Doomsday (Братья Руссо) — 7.03
- 6.I Am Legend 2 (Фрэнсис Лоуренс) — 6.96
- 7.The Devil Wears Prada 2 (Дэвид Френкель) — 6.80
- 8.Spider-Man: Brand New Day (Дестин Креттон) — 6.80
- 9.The Brutalist (Брейди Корбет) — 6.74
- 10.Blade Runner 2099 (Джереми Подесва) — 6.66

ВЫВОДЫ

- 1.Рейтинг фильма можно предсказать с определенной точностью ещё до его выхода, используя только информацию о жанре, режиссёре и актёрском составе. random forest продемонстрировал коэффициент детерминации $R^2 = 0,909$ на тестовой выборке.
- 2.Анализ важности признаков показал, что наибольшее влияние на рейтинг оказывают средний рейтинг актёров, средний рейтинг режиссёра и жанр фильма. Драмы и комедии в среднем получают более высокие оценки, чем, ужасы или боевики. Опыт режиссёра (частота съёмок) также вносит значимый вклад.
- 3.Корреляционный анализ подтвердил ожидаемые связи: рейтинг умеренно коррелирует с мета-оценкой критиков (0,64) и количеством голосов (0,38), но слабо связан с кассовыми сборами (0,25) и практически не зависит от хронометража и года выпуска.
- 4.Кластеризация фильмов выявила четыре устойчивые группы, внутри которых рейтинги варьируются незначительно. Это подтверждает, что схожие по признакам фильмы получают схожие оценки зрителей.
- 5.Прогноз для десяти будущих фильмов показал, что наиболее высокие ожидания связаны с проектами известных режиссёров (Нолан, Скорсезе, Вильнёв) и звёздным актёрским составом. Наименьшая неопределённость прогноза — у фильмов с проверенной командой.